

Scout: Informe Metodológico

Competencia "Tu tiempo, tu Mundial" - Facultad de Ingeniería, Universidad Austral (Junio 2026)

Integrantes: Juan Decoud, Julián Ritondale, Mateo Ritondale, Fernando Santisi

Demo: <https://scout-austral.github.io> Repositorio: <https://github.com/scout-austral/scout-austral.github.io>

1. Resumen ejecutivo

Scout es un sistema de recomendación de partidos del Mundial 2026 que clasifica los 72 encuentros de la fase de grupos en tres categorías: **Imperdible**, **Vale la pena** y **Para ver el resumen**, a partir del perfil de cada usuario.

El problema central es que los partidos aún no se jugaron: no existe verdad de campo que permita entrenar un modelo supervisado clásico. Esta restricción motivó una arquitectura de **elicitación bayesiana de preferencias**: en lugar de aprender de datos históricos etiquetados, el sistema estima la función de utilidad del usuario mediante preguntas informativas, representa esa incertidumbre como distribuciones sobre los pesos, y la propaga al score final para guiar la clasificación y el aprendizaje online.

El sistema se apoya en **8 features por partido**, cuatro de las cuales no son derivables del ranking FIFA (*competitividad*, *grupo de la muerte*, *rivalidad histórica*, *último baile de una leyenda*). La elicitación admite dos modalidades intercambiables: un cuestionario de 8 preguntas, o una descripción en lenguaje natural procesada por un LLM que la traduce automáticamente a los priors del modelo. La demo es pública, funciona sin login y muestra la justificación de cada recomendación junto con la precisión del modelo contra el feedback real del usuario.

2. Problema y datos

Objetivo: dado el perfil de un usuario (afinidad declarada y disponibilidad horaria), recomendar qué partidos de la fase de grupos del Mundial 2026 vale la pena ver y justificar cada decisión.

La restricción central es la **ausencia de datos etiquetados**: ningún usuario ha marcado previamente qué partidos le resultaron imperdibles, y los partidos aún no ocurrieron. Esto descarta el aprendizaje supervisado clásico y motiva una heurística explicable con pesos bayesianos y aprendizaje online por feedback.

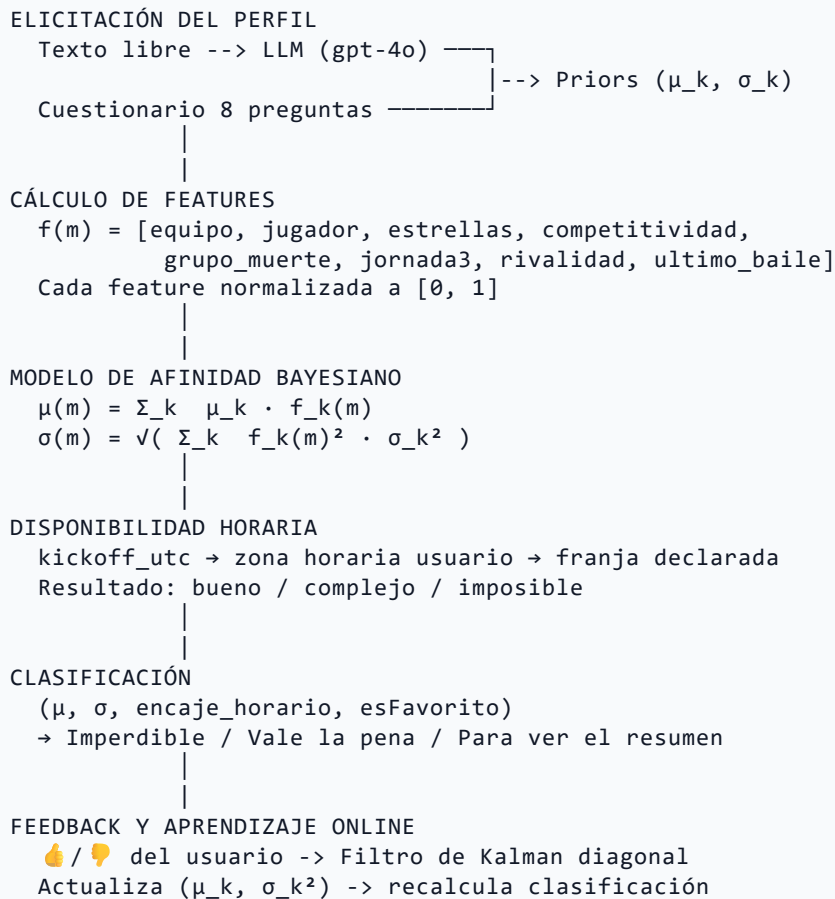
Dataset (estático, versionado en `frontend/src/data/`, generado por `build_data.py`):

- **Fixture y sedes:** 72 partidos de grupos, 48 selecciones, 16 estadios. Cada partido incluye `kickoff_utc` en formato ISO.
- **Ranking FIFA y figuras:** hasta 15 jugadores por selección (218 en total), verificados en mayo–junio 2026.
- **Rivalidades curadas** (`rivalidades.ts`): storylines verificados contra el fixture real (Francia–Senegal revancha de 2002, Inglaterra–Croacia reedición de la semifinal de 2018, entre otros) más un piso automático para derbis de confederación.

- **Último baile** (`ultimoBaile.ts`): figuras en probable último Mundial con intensidad por iconicidad (Messi y Cristiano Ronaldo = 1.0).

El generador valida automáticamente: 72 partidos, round-robin correcto, integridad referencial y la regla FIFA de fecha 3 simultánea en los 12 grupos.

3. Arquitectura del sistema



Arquitectura técnica: la aplicación es completamente client-side (React + TypeScript + Vite), desplegable en GitHub Pages sin backend. Un servidor opcional (Express + OpenAI) enriquece las justificaciones con lenguaje natural; si no está disponible, se usa la justificación local (degradación elegante).

4. Por qué elicitación bayesiana de preferencias

Las alternativas clásicas tienen limitaciones serias en este contexto:

- **Filtrado colaborativo:** requiere historial de muchos usuarios sobre los mismos ítems. No hay historial del Mundial 2026 y los Mundiales anteriores son eventos demasiado espaciados para transferir preferencias.
- **Reglas fijas:** asignar pesos iguales ignora que para un hinchista de Argentina el factor `equipo` vale 10 veces más que `rivalidad`, mientras que para un espectador neutral puede ser al revés.
- **Encuesta exhaustiva:** preguntar por cada combinación de factores es costoso y frustrante.

La **elicitación bayesiana** modela los pesos como variables aleatorias con distribuciones de probabilidad, hace preguntas informativas (las que más reducen la incertidumbre sobre la función de utilidad) y actualiza las distribuciones con cada respuesta.

La incertidumbre se usa activamente en la clasificación:

- **Demote**: un score alto pero con σ grande no alcanza "Imperdible" (no hay suficiente confianza).
- **Promote (UCB)**: un score medio cuyo intervalo optimista $\mu + \sigma$ supera el umbral se promueve a "Vale la pena".

Este enfoque funciona con cero datos históricos, requiere pocas preguntas, es explicable y mejora con el uso sin requerir reentrenamiento.

5. Features del partido

Ocho factores, cada uno normalizado a $[0, 1]$. La fuerza de un equipo se convierte desde su ranking con $\text{fuerza}(r) = \text{clamp}(1 - (r-1)/50, 0, 1)$.

Feature	Fórmula / Valores	Justificación
equipo	$1 - 0.15 \cdot (\text{prioridad} - 1)$ si juega favorito; 0 si no	Factor más determinante: la razón principal para elegir un partido es que juegue el equipo propio.
jugador	$0.7 + 0.3 \cdot (n-1)$ con n = favoritos presentes; 0 si ninguno	Muchos hinchas siguen figuras puntuales por encima de selecciones.
estrellas	$(\text{fuerza}(\text{local}) + \text{fuerza}(\text{visitante})) / 2$	Calibre promedio de los dos equipos; captura el interés del hincha neutral.
competitividad	$\text{clamp}(1 - \text{dist}/30, 0, 1)$ con dist = diferencia de ranking	Partidos parejos generan incertidumbre de resultado: el drama que hace emocionante un partido.
grupo_muerte	$\text{fuerzaProm} \cdot (0.4 + 0.6 \cdot \text{paridad})$	Drama estructural del grupo: no solo equipos fuertes, sino parejos entre sí.
jornada3	$j3 = 1.0 \cdot j2 = 0.25 \cdot j1 = 0$	La tercera fecha se juega simultáneamente; cada resultado puede cambiar el cuadro completo.
rivalidad	Intensidad del storyline curado o piso por derbi	Historia entre selecciones que el ranking ignora (ej. Francia–Senegal revancha de 2002).
ultimo_baile	Intensidad por iconicidad (Messi, CR7 = 1.0); 0 si no aplica	Ver a una figura histórica por última vez trasciende el resultado deportivo.

Los cuatro últimos (**competitividad**, **grupo_muerte**, **rivalidad**, **ultimo_baile**) son los que van más allá del ranking FIFA y diferencian este sistema de un simple ordenamiento por nivel.

6. Modelo de afinidad bayesiano

6.1 Formulación

Cada peso es una variable aleatoria $w_k \sim \text{Normal}(\mu_k, \sigma_k^2)$. El score y su incertidumbre se propagan analíticamente:

$$\begin{aligned}\mu(m) &= \sum_k \mu_k \cdot f_k(m) \\ \sigma(m) &= \sqrt{\sum_k f_k(m)^2 \cdot \sigma_k^2}\end{aligned}$$

6.2 Priors por defecto

Factor	μ	σ	Justificación
equipo	0.30	0.04	Factor dominante universal; σ baja porque es la preferencia más robusta.
jugador	0.16	0.05	Segundo más fuerte; σ ligeramente mayor porque no todos siguen figuras.
estrellas	0.14	0.09	Importa al espectador neutral; σ alta por heterogeneidad entre perfiles.
competitividad	0.14	0.11	Alta incertidumbre: algunos prefieren partidos parejos, otros prefieren ver ganar cómodamente.
grupo_muerte	0.07	0.10	Factor táctico/experto; el más polarizante entre perfiles.
jornada3	0.07	0.08	Contexto de urgencia real pero no domina sobre afinidad por equipos.
rivalidad	0.06	0.10	Magnético para quien conoce la historia; irrelevante para el hincha casual.
ultimo_baile	0.06	0.09	Similar a rivalidad: atractivo narrativo con alta variabilidad entre perfiles.

Las medias suman exactamente 1, por lo que $\mu(m) \in [0, 1]$ cuando todas las features están al máximo: la afinidad es una proporción directamente interpretable.

6.3 Elicitación del prior

a) Cuestionario de 8 preguntas. Cada pregunta mapea la respuesta a uno o más factores (equipos favoritos $\rightarrow$ `equipo`; tipo de hincha $\rightarrow$ `perfilFan`; apetito por la historia $\rightarrow$ `rivalidad` + `ultimo_baile`; etc.). Responder **reduce σ a la mitad** en los factores sobre los que el usuario se pronunció.

b) Asistida por LLM (opcional). El usuario describe en lenguaje natural qué tipo de hincha es. gpt-4o traduce esa descripción a importancia 0–100 por factor, perfil fan, tolerancia y disponibilidad. Resuelve apodos ("la pulga" $\rightarrow$ Messi), clubes a jugadores del Mundial (Real Madrid $\rightarrow$ Vinícius + Mbappé + Bellingham) y regiones a selecciones ("sudamericanos" $\rightarrow$ ARG, BRA, URU, COL, ECU, PAR). El LLM **no recomienda ni clasifica**: únicamente convierte texto a priors.

7. Disponibilidad horaria y clasificación

Disponibilidad: se convierte `kickoff_utc` a la zona horaria del usuario con `Intl.DateTimeFormat` y se mide el solapamiento con las franjas declaradas:

- Dentro de franja $\rightarrow$ **bueno**
- Fuera, a $\leq$ margen de tolerancia $\rightarrow$ **complejo** (baja = 0 h, media = 1.5 h, alta = 3 h)
- Más lejos $\rightarrow$ **imposible**

Un partido imposible cae a Resumen independientemente de su afinidad: no importa cuánto le guste al usuario si no puede verlo.

Clasificación. Los umbrales varían según el perfil declarado (`casual`: alto = 0.6, medio = 0.35; `total`: alto = 0.5, medio = 0.3), con un umbral de incertidumbre $\tau_\sigma = 0.16$. La lógica opera en cascada con cuatro reglas ordenadas por prioridad:

1. **Filtro duro de horario:** si el partido cae en horario imposible, va directamente a Resumen sin importar la afinidad.
2. **Override por favorito:** si juega el equipo o jugador favorito del usuario (señal fuerte), el partido es Imperdible cuando el horario acompaña, o Vale la pena si el horario es incómodo. Esta regla domina sobre el score lineal para evitar que, por ejemplo, Argentina contra un rival de bajo ranking quede degradado.
3. **Score con control de incertidumbre:** si μ supera el umbral alto, el partido es Imperdible siempre que el encaje horario sea bueno y σ sea pequeño (hay confianza suficiente); de lo contrario es Vale la pena.
4. **Criterio UCB:** si μ supera el umbral medio, o si el límite optimista $\mu + \sigma$ lo supera, el partido es Vale la pena. Esto promueve partidos sobre los que todavía hay incertidumbre pero cuyo potencial de interés es real.

8. Aprendizaje online y validación

8.1 Aprendizaje por feedback

Cada 👍 / 👎 actualiza el posterior de los pesos con un filtro de Kalman diagonal ($R = 0.25$):

```

$$\begin{aligned}\hat{y} &= \sum \mu_k f_k \\ e &= y - \hat{y} \\ S &= \sum a_k^2 \sigma_k^2 + R \\ g_k &= \sigma_k^2 \cdot a_k / S \\ \mu_k &\leftarrow \mu_k + g_k \cdot e \\ \sigma_k^2 &\leftarrow \sigma_k^2 \cdot (1 - g_k \cdot a_k)\end{aligned}$$

```

La **saliencia por sorpresa** $a_k = \max(0, f_k - \bar{f}_k)$ asigna crédito solo a lo que destaca en ese partido respecto al promedio del usuario: lo que siempre está presente aporta poca información nueva. La σ angosta en factores afirmados genera ganancia pequeña, por lo que esos pesos casi no se mueven. Un chip "¿qué no te gustó?" permite atribución directa al factor responsable.

8.2 Validación

Sin verdad de campo previa, la validación combina tres enfoques:

Precisión sobre feedback real (visible en la UI). Para cada partido calificado con 👍 / 👎, se mide si el modelo cold-start (priors del onboarding, antes de aprender) lo había predicho correctamente. Se reporta como "acertó X de N (Y%)". Los 👎 por horario se excluyen. Implementado en `accuracy.ts`.

Suite de tests (vitest, 36 casos). Fija el comportamiento esperado en: cálculo de features, conversión de zona horaria, umbrales de clasificación, rol de la incertidumbre, asignación de crédito del aprendizaje y cálculo de precisión.

Escenarios de validez aparente. Un hincha argentino obtiene los partidos de Argentina como Imperdibles; un partido imposible cae a Resumen; una jornada 3 de grupo de la muerte se promueve frente a una jornada 1 entre equipos de nivel similar; un hincha que califica negativamente varios partidos con alta `estrellas` ve ese peso reducirse.

9. Limitaciones y extensiones

Limitaciones conocidas. El dataset de ranking y planteles corresponde a la mejor información disponible a junio 2026 (218 jugadores verificados); variaciones de último momento (lesiones, convocatorias) no se reflejan automáticamente. La disponibilidad se evalúa por día/franja y no modela partidos que crucen medianoche entre días. Las rivalidades curadas dependen de que el cruce exista en el fixture de grupos.

Extensiones posibles. Incorporar clubes seguidos como variable adicional; actualizaciones dinámicas de resultados una vez comenzado el torneo; extensión del modelo a fases eliminatorias; y un estudio con usuarios reales para calibrar umbrales y pesos a priori. La infraestructura de auth, persistencia de perfil y agenda en Google Calendar ya está construida como base para estas extensiones.

Repositorio público con código fuente, dataset e instrucciones de ejecución en:

<https://github.com/scout-austral/scout-austral.github.io>